PROJET DE THÈSE · ReDCAD / FSEG SFAX

Fusion fédérée de profils utilisateurs

Profilage marketing préservant la confidentialité par conception : comprendre les intérêts des utilisateurs pour recommander et cibler — sans jamais stocker ni centraliser leurs données personnelles.

◉ **RAM only · aucune donnée brute persistée**

Architecture 5 couches

Mistral-7B + LoRA · FedAvg · FastAPI + React

LE PROJET

Profiler sans centraliser

Le profilage marketing repose habituellement sur la centralisation de masses de données personnelles — au prix de risques de confidentialité (RGPD), de sécurité et de conformité. Ce système propose l'inverse : un profil riche et utile, construit sans jamais rassembler les données brutes en un seul endroit.

Un profil unifié, exploité dans deux sens

AXE 1 · UTILISATEUR

Recommandation

À partir du profil, proposer à la personne les produits les plus pertinents.

AXE 2 · MARKETEUR

Ciblage

Pour une campagne donnée, identifier les segments de profils les plus affinitaires.

Volume de données entrantes

La source de référence (Amazon Reviews 2023) donne l'ordre de grandeur des données exploitables :

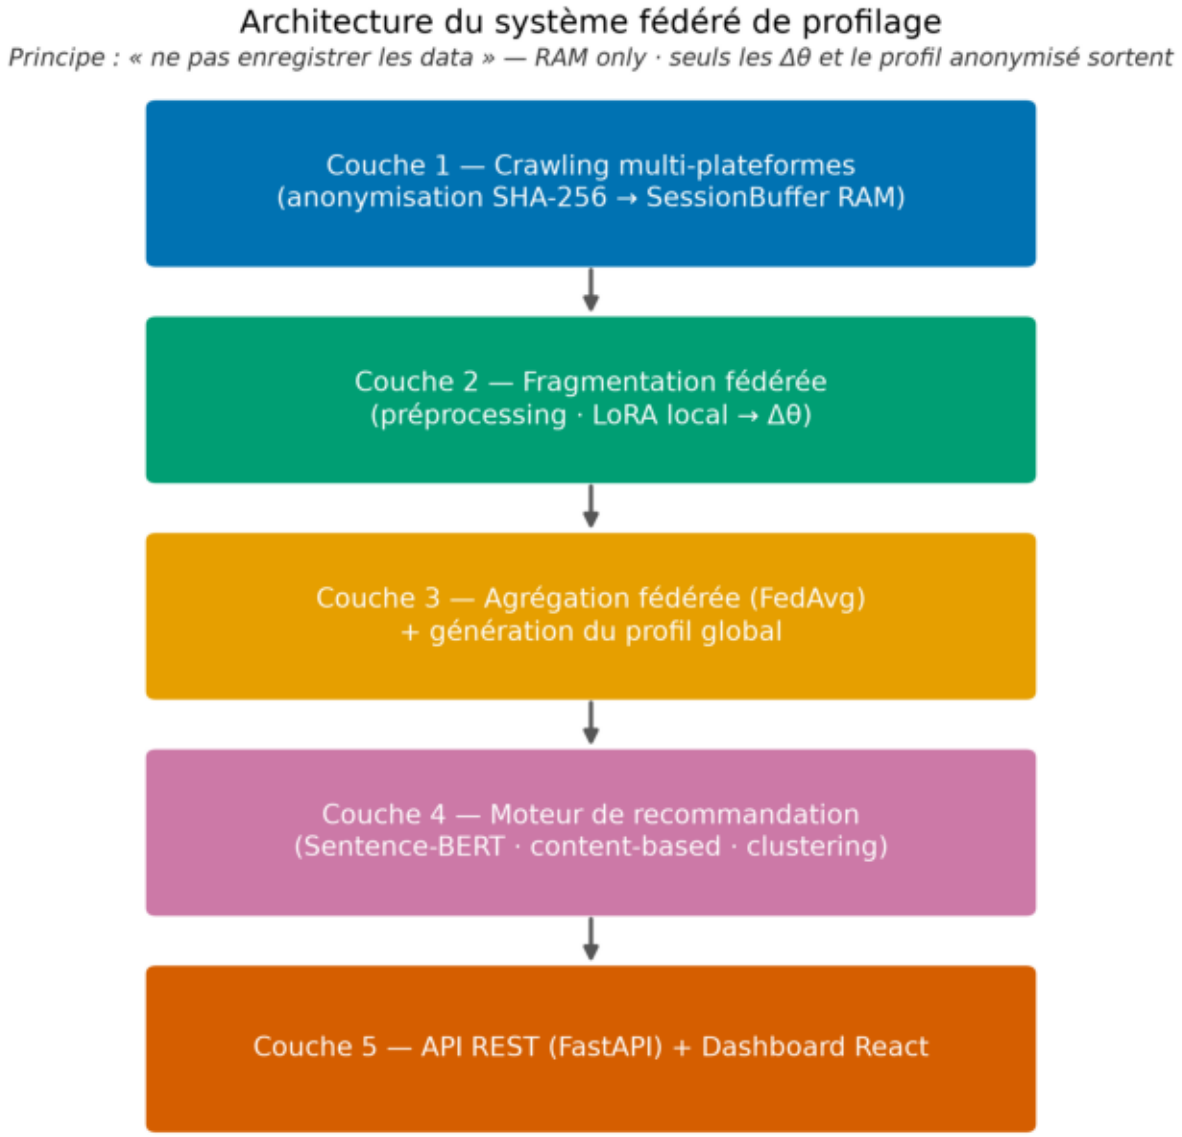
571,54 M	54,51 M	48,19 M	33
avis	utilisateurs	produits	catégories

Streamé un utilisateur à la fois (~58 signaux/profil : posts, commentaires, avis, profil pro), puis la session est vic

Un grand volume reste ainsi compatible avec le principe RAM-only (rien n'est stocké sur disque).

COMMENT ÇA MARCHE

Architecture en 5 couches

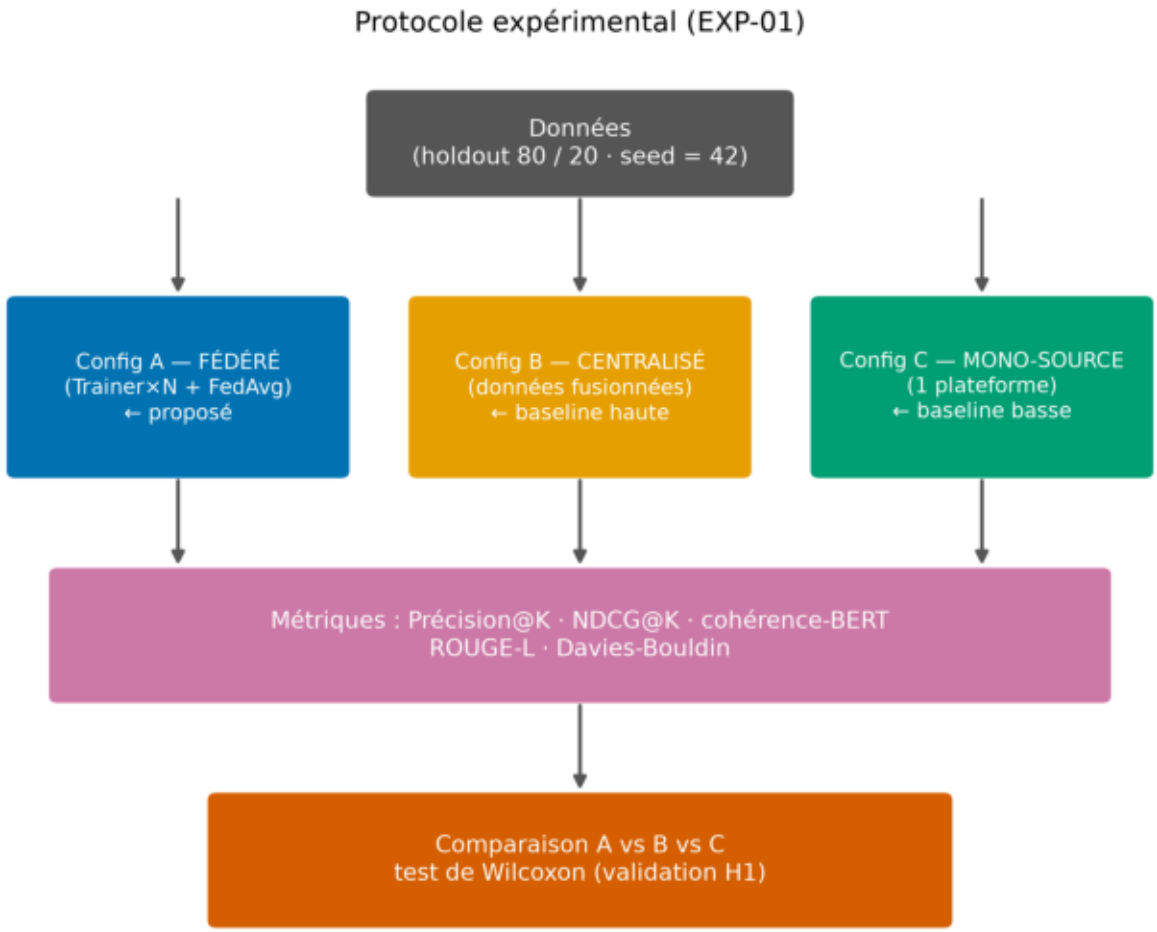


Les 5 couches et le flux de données. Les données brutes ne quittent jamais la RAM ; seuls les Δθ et le profil anonymisé sortent.

MÉTHODOLOGIE

Protocole expérimental

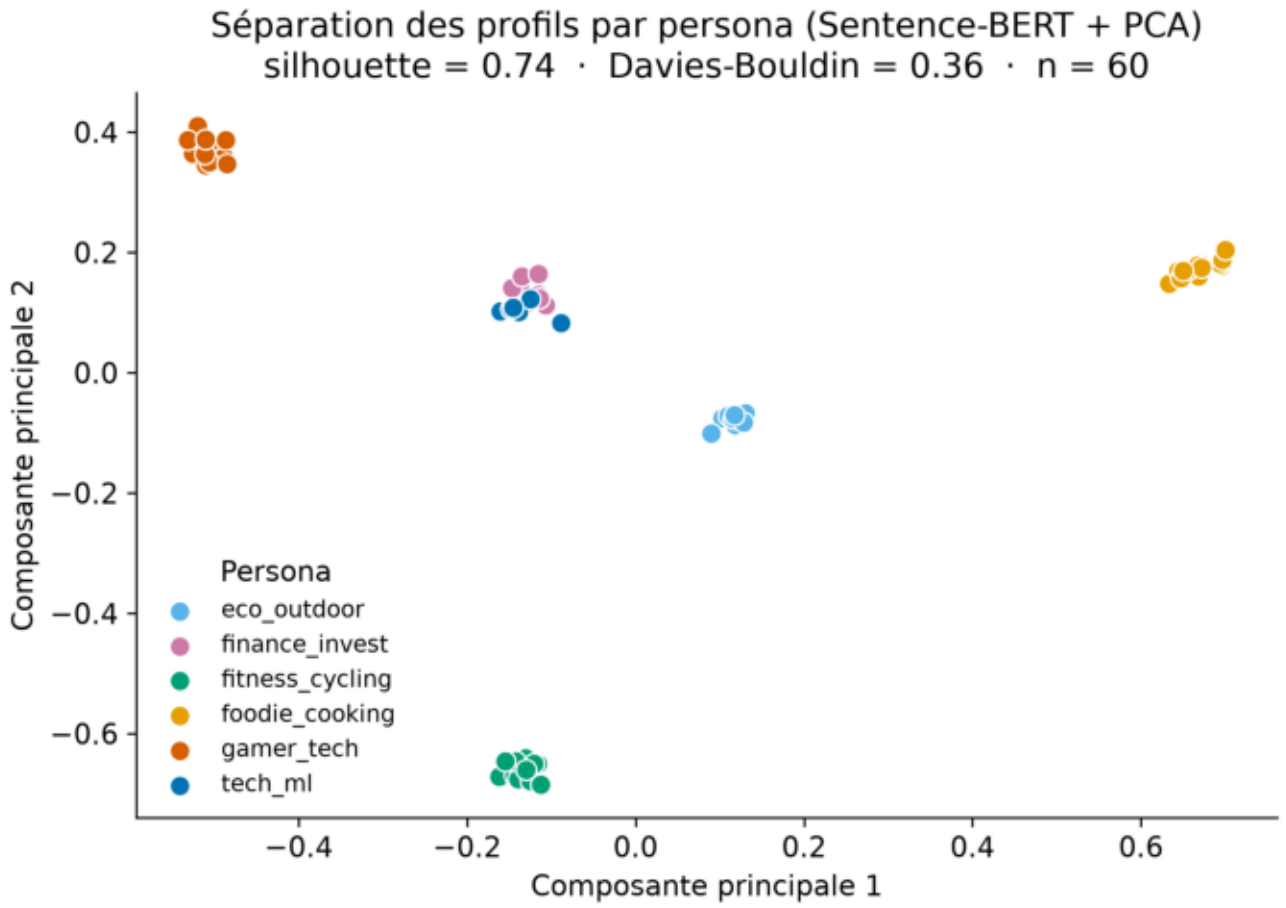
Trois configurations comparées sur les mêmes données, même modèle, même graine : Fédérée (proposée) vs Centralisée (borne haute) vs Mono-source (borne basse). Données conformes : synthétiques reproductibles + catalogue réel Amazon Reviews 2023 (McAuley).



Protocole de comparaison A / B / C (validation de l'hypothèse H1 par test de Wilcoxon).

RÉSULTATS

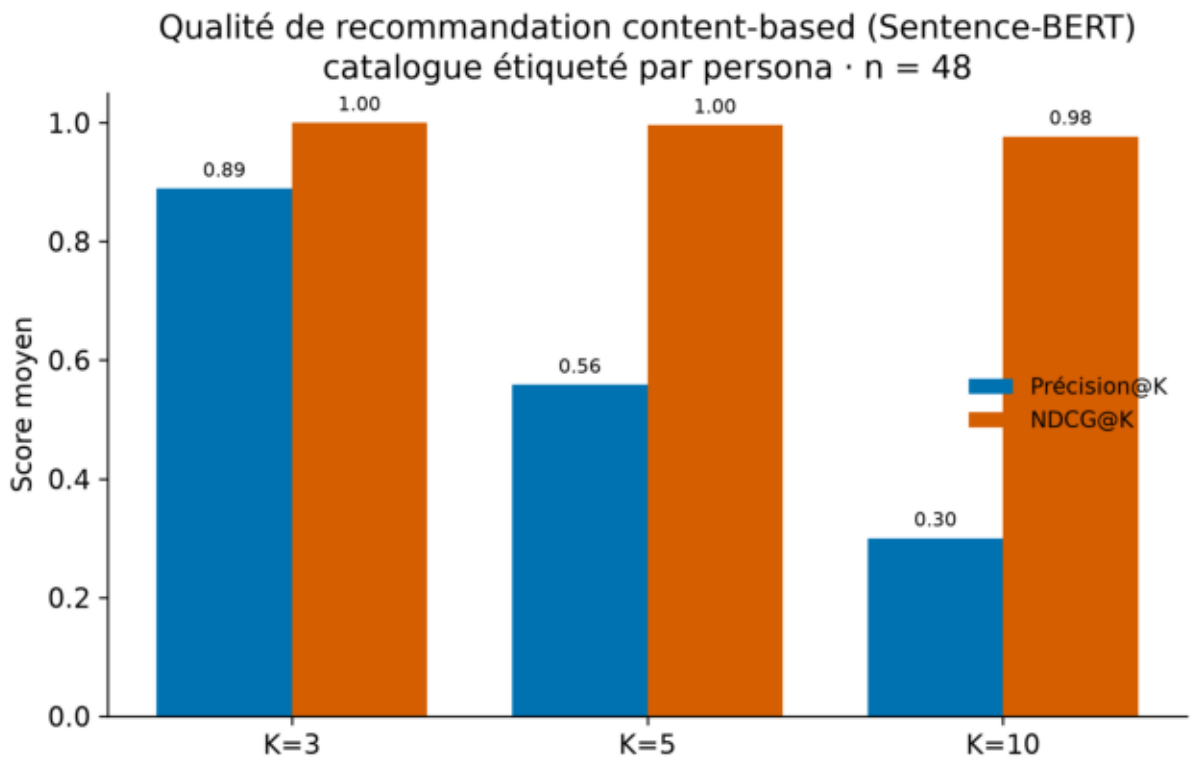
Les profils se séparent par persona



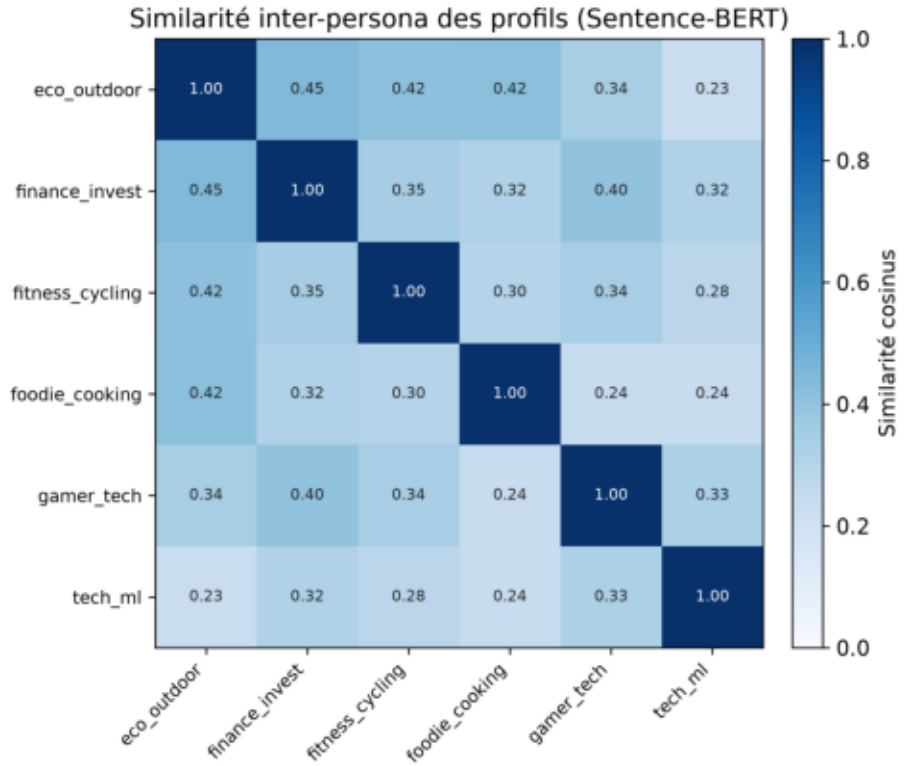
Projection PCA des profils encodés (Sentence-BERT). Séparation nette : silhouette = 0,74 · Davies-Bouldin = 0,36.

Résultat réel et reproductible — fondement du clustering de segments marketing.

Recommandation & similarité



Qualité de recommandation content-based : NDCG@5 = 1,00.



Similarité inter-persona : forte sur la diagonale, faible ailleurs (0,23–0,45).

L'INNOVATION

La confidentialité par conception

- **Apprentissage fédéré**
  Les données ne quittent jamais leur source ; on n'échange que des poids Δθ.

- **« Ne pas enregistrer les données »**
  Tout en RAM, effacé après traitement. Anonymisation SHA-256 dès la collecte.

- **Garanties renforcées**
  Differential Privacy (bruit) + Secure Aggregation (masquage par paires).

Pile technique

- Modèle : Mistral-7B · LoRA / QLoRA 4-bit (peft, trl)
- Fédération : FedAvg · FedProx · Secure Aggregation · Differential Privacy
- Recommandation : Sentence-BERT (all-mpnet) · similarité cosinus · KMeans
- Service : FastAPI (API REST) · React + Vite (dashboard) · MLflow (suivi)
- Validation GPU : RTX 4060 8 Go · pic VRAM ≈ 5,1 Go · 64 tests · CI

Ce que ça produit

- **Profil unifié anonyme**
- **Recommandations de produits**
- **Segments de ciblage**
- **Résultats scientifiques reproductibles**